

电商对话意图类型 × 评估差异化设计

对话式电商 Agent 体验评估标准 V5（完整方案）

文档版本：V5.0 使用对象：产品经理 / 研发同学 / Judge 模型实施方 / 数据分析师 配套文档：[对话式电商Agent自动化评测Prompt_V5.md](#)

第一部分 · 标准框架

一、标准目标

评估对话式电商 Agent 在单轮 / 多轮场景下的最终用户可见结果质量，给出统一、可统计、可归因的结论。

每个 case 最终输出：

- 整体状态（Pass / Needs Work / Fail）
- 5 分制总分（保留 1 位小数）
- 意图类型识别（8 类之一）
- 主问题（main_problem_type）+ 子问题（sub_problem_type）
- 问题总结（中文 1-2 句）
- 关键证据（中文 1 句）
- 链路归因（root_cause）
- 优化建议（中文 1-2 句）

二、V5 相对 V4 的核心改动

#	改动项	V4	V5
1	评估维度数	7 维（含耗时 8%）	6 维（无耗时）
2	评分体系	$answer \times W_a + item \times W_i$ 配比公式	6 维度直接打分加权（无 answer/item 分）
3	维度权重	7 维默认值	6 维新权重（耗时 8% 按比例放大）

4	main_problem_type	8 类（含意图理解 / 结果完整性 / 上下文与交互等中间映射）	直接 = 6 维度 1:1 映射 + 无问题 + 评测输入
5	sub_problem_type 组织	按问题分类挂载	按 6 维度分组挂载，60+ 个 sub
6	维度 5 时效信息评估	看 final_items 字段（被动）	强制 WebFetch URL 实地访问 PDP 核对（主动）
7	item rank 加权	整体公式里用（1/rank）	只在 item-level 维度内部用（维度 1/4/5）
8	卡片样式扣分流向	answer_score -1	维度 6 用户体验 -1
9	OVF-5 触发条件	编造与 final_items 冲突	扩展为"WebFetch URL 验证发现编造"
10	输出新增字段	—	dimension_scores / time_sensitive_verify / item_level_rollup

三、评分模型总览（流程图）



| ② Step 2: 一票否决 OVF-1~9 早检（命中记录，不阻断打分）



| ③ Step 3: 6 维度打分（1-5 各维）

| 维度 1 商品相关性（item-level rollup）

| 维度 2 推荐理由与表达质量（set-level）

| 维度 3 完整性与多样性（set-level）

| 维度 4 事实准确性（item-level rollup）

| 维度 5 时效信息可信度（item-level + URL 验证）

| 维度 6 用户体验（混合）

| $\text{per_turn_score} = \sum(\text{维度分} \times \text{意图权重})$

| 单轮: $\text{case_overall_score} = \text{per_turn_score}$

▼ (仅多轮)

| ④ Step 4: 跨轮 4 维度评分

| context / goal / progression / closure



| ⑤ Step 5: 多轮总分

| $\text{case_overall_score} = \text{weighted_turn} \times 45\%$

| $+ \text{goal} \times 25\% + \text{context} \times 15\%$

| $+ \text{progression} \times 10\% + \text{closure} \times 5\%$



⑥ Step 6: 状态判定

OVF → Fail · ≥ 4 Pass · 3-4 NW · < 3 Fail



⑦ Step 7: 单一诊断

main_problem_type = 拉低分最重的维度 (1:1)

sub_problem_type = 该维度下的具体失败模式



⑧ Step 8: 链路归因 root_cause

no_issue / data_quality / retrieval / generation / ...

☒四、核心原则（评估时的取舍依据，优先级从高到低）

- 最终结果优先：**总分只评用户最终看到的结果（answer_text + final_items + render_data）；tool 层只用于归因，不影响打分。
- 目标达成第一（多轮）：**多轮评估首先看用户最终目标是否完成，达成不达成对总分权重最高（goal × 25%）。
- 相关性严格：**推荐 / 对比 / closing 轮中出现不完全相关商品 → 一票否决 Fail。
- 6 维度独立打分：**商品相关性 / 推荐理由与表达 / 完整性与多样性 / 事实准确性 / 时效信息可信度 / 用户体验。每维度独立评 1-5 分，互不混淆。

- e. **维度 5 强制 URL 验证**：评时效信息可信度时，Judge 必须实地访问 `final_items[].url` 对照 PDP 真实数据；不可访问则按降级矩阵处置。
- f. **单一主因**：每个 case 只标注一个最主要问题（`main_problem_type`），与 6 维度 1:1 映射。
- g. **证据优先级**：
- ☑ 用户输入 > `history_context`
 - > tool 返回的 `final_items / render_data[].product`
 - > 商品详情页（URL 实地验证）
 - > `expected_outcome` > 常识
 - ☒
- `final_items` 与 `render_data[].product` 是**既定事实证据**（维度 4 用）
 - `final_items[].url` 对应的 PDP 是**时效信息证据**（维度 5 用）
 - 证据不足不判事实错。
- h. **卡片样式只看 `render_data`**：判断卡片类型一律读 `render_data[].type`，不要扫 `answer_text` 正文里有没有内联标记（V4 模型正文里没有这种标记）。
- i. **卡片样式扣分流向维度 6**：卡片样式问题不再独立扣 `answer_score`，而是直接影响维度 6 用户体验分。

第二部分 · 评估准备

五、输入字段规范

5.1 通用字段（单/多轮共用）

字段	类型	说明
<code>personal_context</code>	字符串/对象	用户个人信息（仅上下文，不直接影响打分）
<code>history_context</code>	字符串/对象	历史对话信息（仅上下文）
<code>expected_outcome</code>	字符串/对象	预期输出（辅助参考，可能为空）

5.2 单轮专用

字段	类型	说明
----	----	----

input_message	字符串	当前用户 query
input_additional	字符串/对象	附件（图/语音等），无则填"无"
actual_outcome	对象	含 final answer + final items + render_data + tool 调用结果

5.3 多轮专用

字段	类型	说明
conversation_turns[]	数组	每轮含 user_query / user_attachments / agent_answer / agent_items / render_data / tool 调用与返回

字段缺失视为空，不臆测未呈现内容。

5.4 actual_outcome 结构详解（render_data 数组模型）

Agent 输出由 4 部分组成：

```
{
  "actual_outcome": {
    "answer_text": "正文回答（含 markdown 链接 [商品名](url) )",
    "final_items": [
      {
        "item_id": "item id_123",
        "title": "商品名",
        "description": "...",
        "price": "S$129",
        "rating": 4.7,
        "review_count": 1203,
        "sales": 5800,
        "seller": "Naturehike Official Store",
        "official_store": true,
        "ship_from": "Singapore",
```

```
    "stock": "in_stock",

    "image_url": "https://...",

    "attributes": {"weight": "1.5kg", "color": "green"}
  }
],

"render_data": [
  {"type": "item_hero_card", "ref_id": "item_123", "position": 1, "product": {...}},
  {"type": "item_mini_card", "ref_id": "item_456", "position": 2, "product": {...}}
],

"tool_calls": [...]
}
}
```

☒5.5 render_data 5 类卡片字段规范

type	含义	必需字段
item_hero_card	单商品大卡（主推 / 详情商品）	ref_id + product
item_mini_card	单商品小卡（多商品并列 / 备选）	ref_id + product
image_gallery	多图轮播	ref_id + product + images（数组，应 ≥ 2 张）
item_link	正文内文字链接	ref_id + product + text（简短可读标签）
item_comparison_table	商品对比表	ref_ids（数组）+ products（完整数组）+ attributes（每项含 key/label/values{ref_id: 值}/preferred_ref_ids）。没有 table_ref_id 字段，不要去找。

5.6 解析逻辑（务必遵守）

- a. 判断卡片类型：一律读 render_data[].type，不要扫 answer_text 正文里有没有 <item_hero_card> 等内联标记。

- b. 正文 markdown 链接 [商品名](url)：这是卡片锚文本，由 position 映射对应卡片，不算"缺卡"或"卡片用错"。
- c. 取商品真实信息：从 render_data[].product（或 final_items 经 ref_id 关联）拿真实标题/价格/评分/属性。
- d. render_data 缺失时（旧格式/未采集）：跳过卡片样式评估；仅当 should_recommend=yes 且工具已返回商品而正文里连商品链接都没有时，才按 card_missing 处理（走 OVF-4）。
- e. tool 识别：tool 调用与返回字段名不固定（tool_calls / tool_response / function_call / observations / intermediate_steps，或嵌在 actual_outcome 内）。按语义识别是否调用 tool，不能因找不到 tool_calls 字段就判"未调用"。

第三部分 · 评估流程

六、Step 1 — 范围 / 场景 / 意图 / 角色识别

6.1 eval_scope（评估范围）

eval_scope	适用	总分口径
single_turn	仅一次用户输入与一次 Agent 输出	直接走每轮分公式
whole_conversation	完整多轮对话	走多轮加权公式
specific_turn	只评某一轮，但需完整上下文参考	目标轮详评；case_overall_score 仍按整段计算

6.2 intent_type（意图类型，8 类，每 case 选 1）

intent_type	定义	示例
precise_lookup	已知具体型号 / SKU，几乎无歧义	"iPhone 15 Pro 256GB 黑色"
semi_precise_lookup	品类 + 部分约束（品牌 / 预算 / 规格 / 人群）	"5000 元能打游戏的笔记本"、"男士 42 码白色跑鞋"
vague_lookup	仅品类，几乎无约束；或问某商品值不值 / 怎么样	"推荐个手机"、"想买条裙子"、"这个羽毛球拍怎么样"
scenario_lookup	用途 / 场合驱动，需要 Agent 推断合适品	"露营装备"、"开斋节穿搭"
compare	比较指定的 A/B/C	"iPhone 16 vs S24"

how_to_choose	问怎么选、看什么标准	"油性头发怎么选洗发水"
detail_qa	追问已知商品的规格/尺码/兼容/保修	"A7 IV 有机身防抖吗"
others	上述无法归类的电商意图（如售后/订单/物流/送礼/以图搜/纯交易信息查询）+ non-commerce	"怎么退货"、"送朋友礼物推荐"

6.3 turn_role（轮次角色）

turn_role	定义
initial_query	用户首次提出需求
agent_clarification_turn	Agent 主要在追问缺失信息
user_clarification_response	用户回答上一轮澄清问题
refinement	用户新增或调整约束
comparison_request	用户明确要求比较
detail_qa	用户追问已展示商品
closing	用户明确要购买链接、下单、最终推荐、购买地址
other	寒暄、跑题、无法归类

closing 不能仅因为是最后一轮就成立，必须出现明确购买 / 决策语义。

6.4 should_recommend（推荐必要性）

情况	should_recommend
找商品 / 要推荐 / 要对比	yes
用户已补充足够约束后等待候选	yes
用户明确要购买链接 / 下单 / 最终推荐	yes
纯知识 / 方法咨询	no
已推荐商品追问	no
Agent 合理澄清	no

non-commerce	no
--------------	----

七、Step 2 — 一票否决（OVF）早检

命中任一 → case 直接判 Fail，但仍跑完打分用于诊断细化。

7.1 OVF 9 条规则

编号	规则
OVF-1	推荐 / 对比 / closing 轮中，任一商品不完全相关
OVF-2	用户明确否定 / 排除后，Agent 仍继续推荐
OVF-3	商品对比时漏掉核心比较对象
OVF-4	明确购买意图时应推未推（render_data 为空且 answer_text 也无任何商品链接 → 视为未返回商品，走 card_missing / no_product_card）
OVF-5	编造价格 / shipping / 库存 / seller / 官方店等交易信息（通过 URL 实地验证发现，或与 final_items / render_data[].product 冲突）
OVF-6	健康 / 儿童 / 药品 / 孕产 / 安全场景给确定性误导建议
OVF-7	用户明确想下单但无购买承接
OVF-8	连续 3 轮以上重复澄清，且用户已提供足够信息
OVF-9	多轮无响应 / timeout 导致目标无法完成

7.2 按意图差异化 OVF 适用

intent_type	主要适用 OVF	特别说明
precise / semi_precise / scenario_lookup	OVF-1（相关性）、OVF-5（交易信息）	相关性从严
vague_lookup	OVF-1 适度	同大类不算错，偏离关键约束才扣
compare	OVF-3（漏对象）+ OVF-1	漏核心对比对象最严重
how_to_choose	几乎不触发推荐类 OVF	should_recommend 多为 no
detail_qa		重在不编造

	OVF-5（编造） / OVF-6（高风险误导）	
others	按场景全套 OVF-1~9	—

八、Step 3 — 6 维度打分

8.1 6 维度定义

#	维度	默认权重	评分类型	子项构成
1	商品相关性	24%	item-level rollup	品类相关性 + 品牌相关性 + 约束相关性 + 价格相关性
2	推荐理由与表达质量	20%	set-level	语言结构 + 理由具体度（事实锚点）+ 决策辅助深度（if-then 框架）+ 教育性
3	完整性与多样性	16%	set-level	候选数 + 品类多样性 + SPU 多样性 + Offer 多样性 + 风格/价位多样性 + 下一步承接
4	事实准确性（既定事实）	13%	item-level rollup	商品属性 / 品牌型号身份 / 描述-商品一致性
5	时效信息可信度	13%	item-level + URL 验证	价格 + 库存 + 物流 + 促销 + 卖家身份
6	用户体验	14%	混合	卡片样式（set-level）+ 推荐商品销量/评分质量（item-level）

8.2 意图差异化权重总表

维度	precise_looku p	semi_p recise	vague	scenari o	compar e	how_to _choos e	detail_ qa	others
----	--------------------	------------------	-------	--------------	-------------	-----------------------	---------------	--------

1 商品相关性	33%	27%	22%	22%	24%	20%	24%	默认 24%
2 推荐理由与表达	16%	16%	20%	20%	22%	33%	32%	默认 20%
3 完整性与多样性	9%	20%	22%	24%	13%	20%	5%	默认 16%
4 事实准确性	16%	13%	13%	13%	17%	11%	22%	默认 13%
5 时效信息可信度	16%	13%	13%	11%	13%	8%	9%	默认 13%
6 用户体验	10%	11%	10%	10%	11%	8%	8%	默认 14%
合计	100%	100%	100%	100%	100%	100%	100%	100%

加粗 = 该意图下权重显著高于默认值的维度（评估时最该关心）；others 走默认权重

8.3 权重逻辑速读

意图	高权重组合	合计	评估侧重
精准找商品	相关性 33% + 事实 16% + 时效 16%	65%	找对 SKU + 价格真 + 能买到
半精准找	相关性 27% + 多样性 20% + 推荐理由 16%	63%	多档差异化
模糊找	多样性 22% + 相关性 22% + 推荐理由 20%	64%	选择面 + 收敛框架
场景化找	多样性 24% + 相关性 22% + 推荐理由 20%	66%	场景拆解完整
商品对比	相关性 24% + 推荐理由 22% + 事实 17%	63%	覆盖 + 差异 + 数据准
选购指导	推荐理由 33% + 多样性 20% + 相关性 20%	73%	讲清方法 + 分档示例
属性问答	推荐理由 32% + 相关性 24% + 事实 22%	78%	答得对 + 不编造

九、6 维度详细评估（含锚点 + 子项 + 评估样例）

9.1 维度 1 — 商品相关性

评分类型：item-level rollup（每个 item 单独打分，按 1/rank 加权汇总）

子项分解：

子项	定义	何时适用
品类相关性	商品 L1/L2 品类是否命中用户隐含或显式的品类需求	所有意图
品牌相关性	用户提到品牌偏好或具体品牌时，结果是否匹配 brand	仅当用户提到品牌（含正向/否定）
约束相关性	返回商品是否满足用户的所有显式约束（规格/颜色/尺寸/人群/用途/材质等）	仅当用户提了约束
价格相关性	用户给出预算或价位时，结果价格是否落在范围内	仅当用户提了预算

当需求为场景化找商品、无品类约束时，品类相关性可放宽。

1-5 分锚点：

分	锚点
5	全部候选 ☒ 品类对 ☒ 品牌对 ☒ 所有约束满足 ☒ 价格在范围
4	主候选全满足 + 少数 1 个偏边缘但已标注
3	品类对但漏 1-2 个约束（如要"防水徒步鞋"给普通休闲鞋）
2	多数候选不符合核心约束 / 品牌全错（用户指定时）
1	错品类 / 错品牌 / 完全忽略否定条件（触发 OVF-1 或 OVF-2）

评估样例（3 档锚点）：

☒ Good Case（5 分）：

☒query: "iPhone 15 Pro 256GB 黑色"

agent 推: iPhone 15 Pro 256GB Black (Apple 官方旗舰店)

评分理由: 品类对 (手机/iPhone) + 品牌对 (Apple) + 存储 256GB 满足
+ 颜色黑色满足 + 价格无约束

☒

🟡 Middle Case (3 分) :

☒query: "5000 元能打游戏的笔记本"

agent 推: ① Y9000P ¥4999 ② 战神 G9 ¥4799 ③ 华硕天选 4 OLED ¥5800 (超预算未标注)

评分理由: 品类对 (笔记本) + 用途对 (游戏本)
但第 3 款超约束未标注 (constraint_mismatch 1 项) → 3 分

☒

❌ Bad Case (1 分) :

☒query: "Find a brand-new iPhone, not refurbished"

agent 推: Refurbished iPhone 15 Pro

评分理由: 直接违反否定条件 "not refurbished" → OVF-2 触发
→ 维度 1 强制 1 分 + status = Fail

☒

子项在不同意图下的优先级:

意图	品类	品牌	约束	价格
精准找	★★★★ 严	★★★★ 严	★★★★ 严	★★★★ 严
半精准找	★★★★ 严	★★★ 中	★★★★ 严	★★★★ 严
模糊找	★★★ 中	NA	NA	NA
场景化找	★★★★ 严 (跨品类合理性)	NA	★★★ 中	★★★ 中
探索型	★ 宽 (同领域即可)	NA	NA	NA
对比	★★★★ 严 (对象本身)	★★★★ 严 (指定品牌)	NA	★★★ 中

9.2 维度 2 — 推荐理由与表达质量

评分类型: set-level (评 agent 整体推理质量, 不分 item)

子项分解：

子项	定义	评估方法
语言结构与可读性	答案分段清晰、关键信息突出、可快速扫读	看是否能 10 秒抓到结论
推荐理由具体度（事实锚点）	含数字 / 具体技术词 / 形象比喻 / 明确功效	数事实锚点密度
决策辅助深度	trade-off / 优先级 / if-then 决策框架	看回答中是否含"如果你 X 就选 A，如果 Y 就选 B"逻辑
教育性	解释关键术语 / 选购维度 / 行业常识	看是否含科普段落

事实锚点分级（评维度 2 的核心信号）：

锚点类型	示例	优先级
数值锚点	"Lightweight at 0.84 lbs" / "SPF 30 / 100% DCI-P3"	★★★★
技术术语	"Nitrogen-infused midsole" / "氨基酸表活"	★★★★
形象比喻	"Sock-like fit" / "如袜子般贴合"	★★★
明确功效	"Reduces joint pain" / "控油 8 小时"	★★★★
具体场景	"Ideal for trail running"	★★★
设计细节	"Knit bootie design" / "针织鞋套设计"	★★★

1-5 分锚点：

分	锚点
5	结构清晰 + 含数字/技术词锚点 + 含 ≥ 2 档 if-then 决策框架 + 含术语解释
4	结构清晰 + 部分具体理由 + 有 trade-off 说明

3	可读 + 理由偏通用 ("good for daily use") + 无明显决策框架
2	一团长文 + 全通用词 (comfortable / durable) + 无决策辅助
1	难读 / 全空话 / 误导决策

评估样例：

✔ Good Case（5 分）：

☒"如果你主要玩 LOL/原神等网游 → 联想小新 Pro 16 中配版就够（省钱+发热小）；
如果要玩赛博朋克 2077 这类 3A 大作 → 必须 RTX 4060 及以上，优先考虑天选 Air
（1.46kg、19.9mm、2.5K 165Hz 100% sRGB）"

评分理由：

- 数字锚点密：1.46kg / 19.9mm / 165Hz / 100% sRGB
- if-then 决策框架完整：if 网游 → A；if 3A → B
- 含术语解释（隐式说明为何 RTX 4060+ 才能跑 3A)



● Middle Case（3 分）：

☒"这款电脑屏幕画质顶级，性能强劲，是兼顾创意工作和游戏的理想选择。"

评分理由：

- 可读但全通用词 ("顶级 / 强劲 / 理想")
- 0 个事实锚点
- 无 if-then 决策框架



✖ Bad Case（1 分）：

☒"这款手机完美无缺，相信你不会后悔，强烈推荐！"

评分理由: 全空话 + 误导承诺 ("完美无缺"涉嫌 OVF-6 风险)



9.3 维度 3 — 完整性与多样性

评分类型：set-level（多样性本就是 set 维度，不分 item）

子项分解：

子项	定义	重点意图
候选数完整性	是否给出足够数量的候选（按 intent 调整：精准 1，半精准/模糊 3-5）	所有意图
品类多样性	跨品类覆盖（场景化下避免集中在 1 个品类）	场景化、探索型
SPU 多样性	同品类内不同款型 / 系列覆盖（避免同店伪 SPU 重复）	半精准、模糊
Offer 多样性	同 SPU 下不同商家 / 价格 / 物流的 offer 覆盖	精准找、购买承接
风格/价位/品牌多样性	覆盖不同档位、风格、品牌	模糊找、探索型
下一步承接	refine / 追问 / 折叠备选入口	模糊找、探索型

1-5 分锚点：

分	锚点
5	候选数充足 + 多维多样（品类/SPU/Offer/风格/价位） + 清晰下一步承接
4	主候选齐全，1 个维度略弱（如品牌集中 or 缺下一步建议）
3	候选偏少 or 品类不齐 or SPU 同质化（如同店伪 SPU 重复）
2	仅 1 个候选 or 反复同款 or 收敛过度
1	完全无承接 or 完全无候选

评估样例：

✔ Good Case（5 分）：

☒query: "5000 元能打游戏的笔记本"

agent 推: ① Y9000P（综合性能向）② 战神 G9（性能强但散热噪音大）

③ 雷神 911X（性价比之王）④ ROG 魔霸（240Hz 高刷屏）

+ 顶部排序逻辑（综合性能+散热+屏幕）

+ 末尾"放宽到 ¥5500 → 华硕天选 4 OLED 更香"

评分理由: 4 款差异化定位（性能/性价比/散热/屏幕 4 维度）+ 排序逻辑 + 备选承接



● Middle Case（3 分）：

☒query: "日常休闲衬衫"

agent 推 5 款，但 item[0] 和 item[1] 同 shop_id (564494110)

同价 ¥56.800、description 几乎一字不差

评分理由: 候选数 5 够，但 SPU 多样性差（同店伪 SPU 重复，触发 low_spu_diversity）

→ 维度 3 = 3 分



✖ Bad Case（1 分）：

☒query: "推荐个手机"

agent: "推荐 iPhone 15 Pro，2023 年苹果旗舰，性能强劲。"

评分理由: 只推 1 款不解释 + 无切片引导（价位/用途）+ 无下一步追问

→ 维度 3 = 1 分



子项在不同意图下的权重侧重：

意图	候选数	品类多样性	SPU 多样性	Offer 多样性	风格多样性	下一步承接
精准找	单选	NA	NA	★★★★ 重	NA	NA
半精准找	3-5	NA	★★★★ 重	★ 中	★★★ 中	★★★ 中
模糊找	5-10	NA	★★★★ 重	NA	★★★★ 重	★★★★ 重
场景化找	5-10	★★★★ 重	★★★ 中	NA	★ 弱	★★★ 中
探索型	5-10	★★★ 中	★★★ 中	NA	★★★★ 重	★★★★ 重
对比	2-3	NA	NA	NA	NA	★ 中
选购指导	2-3（示例品）	NA	★ 弱	NA	★ 弱	★★★ 中

9.4 维度 4 — 事实准确性（既定事实）

评分类型: item-level rollup（对每个 item 单独评事实准确性，按 1/rank 加权）

评估对象: 商品属性 / 品牌型号身份 / 描述-商品一致性等静态既定信息

子项分解：

子项	定义	评估方法
商品属性事实性	参数 / 规格 / 材质 / 尺寸等是否对得上真实商品数据	对照 <code>final_items[].attributes</code>
品牌 / 型号身份事实性	agent 说的品牌 + 型号是否与实际商品一致	对照 <code>final_items[].title</code> 和 <code>brand</code>
描述-商品一致性	agent 的推荐理由是否描述的就是实际推荐的那个商品	对照 <code>final_items</code> 整体

1-5 分锚点：

分	锚点
5	全部既定信息可对照 <code>final_items / render_data[].product</code> 验证 + 数据不足时透明声明
4	主要信息可信，1-2 处粗略表达但无误导
3	偶有夸大或推测但未直接证伪
2	部分关键信息明显夸大（如把 2.7kg 说成"轻薄"）
1	商品标题/品牌/规格被直接证伪（触发 OVF-5 风险）

评估样例：

✔ Good Case（5 分）：

☒agent: "ROG 幻 16 G16 OLED 240Hz，机身 1.85kg"

`final_items[0].attributes: {"display": "OLED 2.5K 240Hz", "weight": "1.85kg"}`

评分理由: 完全一致，可对照验证 → 5 分

☒

● Middle Case（3 分）：

☒agent: "微星泰坦 16 AI 性能向里算轻薄"

`final_items[2].attributes.weight: "2.7kg"`

评分理由: 2.7kg 标"算轻薄"是轻微夸大但未直接证伪 → 3 分

sub: overconfident_product_claim



✖ Bad Case（1 分）：

☑agent: "首推 ASUS ROG Zephyrus G14（2025），14 寸 OLED 屏"

final_items[0].name: "ASUS TUF A16 FA607NUG"

final_items[0].attributes: {"display": "15.6 inch FHD+ IPS"}

评分理由: 商品名/品牌/规格三重错位（ROG≠TUF, 14"≠15.6", OLED≠IPS）

→ 直接证伪 → OVF-5 → 维度 4 = 1 分

sub: directly_contradicted_claim / wrong_brand_or_model_info



9.5 维度 5 — 时效信息可信度 ★ V5 强制 URL 验证

评分类型：item-level + URL 实地验证（按 1/rank 加权汇总）

评估对象：价格 / 库存 / 物流 / 促销 / 卖家等动态实时信息

子项分解：

子项	定义
价格信息	当前价格 / 促销价是否与 PDP 一致
库存状态	"现货 / 缺货 / 预售"是否真实
物流 / shipping	"次日达 / X 天到货"是否准确
促销 / 优惠	"国补 / 满减 / 限时折扣 / 会员价"是否真实
卖家身份	"官方店 / 自营 / 第三方"是否真实

9.5.1 强制 URL 验证流程（6 步）

☑Step A: URL 提取

└─ 从 final_items[].url 或 render_data[].product.url 提取每个商品 URL

└─ 若 URL 缺失 → 该商品标记 time_sensitive_unverifiable，默认 3 分

Step B: 调用 WebFetch 实地访问

└─ 对每个 URL 调用 WebFetch(url)

└─ 失败 → 该商品标记 fetch_failed，默认 3 分

└─ 成功 → 进入 Step C

Step C: PDP 数据抽取

从返回 HTML 中提取：

- 当前价格 (current_price)
- 库存状态 (stock_status: in_stock / out_of_stock / preorder)
- shipping / 物流 (shipping_info)
- 促销标签 (active_promos: 满减 / 国补 / 限时折扣 / 会员价)
- 卖家身份 (seller_name + official_store 标识)

Step D: 对照 agent answer_text 中的相应陈述

逐字段比对，记录 diffs

Step E: 按下表给该 item 的维度 5 打分

Step F: 将所有 item 的维度 5 分按 1/rank rollup 得维度 5 总分

☒9.5.2 打分规则

情况	该 item 分	sub_problem_type
全部字段一致	5	—
1-2 字段略偏差 (< 5%)	4	—
中等偏差 (5-20%)	3	price_inaccuracy
明显偏差 (> 20%)	2	price_inaccuracy
凭空编造 (差异极大或字段完全错)	1 + OVF-5	fabricated_price / fabricated_promo / fabricated_stock

9.5.3 URL 验证降级矩阵

情况	该 item 分	sub_problem_type
URL 字段缺失	3 (默认)	time_sensitive_unverifiable
WebFetch 失败 / 404 / timeout	3 (默认)	time_sensitive_unverifiable；连续 ≥ 2 个失败 → 维度 6 加挂 dead_link
WebFetch 返回聚合搜索页非 SKU 详情页	3	link_to_aggregation_page
WebFetch 受 region 限制无法访问	3	time_sensitive_unverifiable

9.5.4 输出 `time_sensitive_verify` 字段

每个 item 的验证结果必须写入

`score_breakdown.per_turn_scores[].time_sensitive_verify.verified_items[]`:

```
{
  "item_id": "item_123",
  "url": "https://item.sg/...",
  "fetch_status": "ok | failed | aggregation_page | url_missing | region_blocked",
  "diffs": {
    "price": {"agent_claim": "¥7899", "pdp_truth": "¥7899", "match": true},
    "stock": {"agent_claim": "in_stock", "pdp_truth": "in_stock", "match": true},
    "promo": {"agent_claim": "国补 15%", "pdp_truth": "国补 15%", "match": true},
    "shipping": {"agent_claim": "次日达", "pdp_truth": "211 限时达", "match": false},
    "seller": {"agent_claim": "JD 自营", "pdp_truth": "JD 自营", "match": true}
  },
  "per_item_dim5_score": 4
}
```

9.5.5 评估样例

✓ **Good Case (5 分) :**

☒ agent: "JD 自营 ¥7899, 限时立减 ¥100, PLUS 95 折后 ¥7504"

WebFetch(url) → PDP:

current_price: ¥7899

active_promos: ["限时立减 100", "PLUS 价 ¥7504"]

seller: "JD 自营"

评分理由: 价格/促销/会员价/卖家全对 → 5 分

☒

● **Middle Case (3 分) :**

☒ agent: "iPhone 15 Pro 256GB 约 ¥7000-8000, 具体看哪家"

final_items[0].url: null (字段缺失)

评分理由: 信息粗略 + URL 缺失 → `time_sensitive_unverifiable`

→ 该 item 默认 3 分

☒

✖ Bad Case（1分）：

☒agent: "JD 当前秒杀 ¥4999，国补 50% 后 ¥2499，明天涨价"

WebFetch(url) → PDP:

current_price: ¥7899

active_promos: [] (无国补、无秒杀)

评分理由：

- 价格偏差 60%（凭空编造）

- 编造促销（"国补 50%"、"秒杀"、"明天涨价"均不存在）

→ 该 item = 1 分 + 触发 OVF-5

sub: fabricated_price

☒

9.6 维度 6 — 用户体验

评分类型：混合（卡片样式 set-level + 推荐商品质量 item-level，取最低值）

子项分解：

子项	评分类型	评估对象
商品卡完整度与美观	set-level	render_data 卡片字段完整性
多模态承载	set-level	图片 / 视频 / 对比表等
推荐商品销量 / 评分 / 卖家质量	item-level rollup	final_items[].sales / rating / seller

1-5 分锚点：

分	锚点
5	信息丰富商品卡 + 多模态承载 + 推荐 SKU 是大牌/认证商家 + 高销量/高分
4	完整商品卡 + 真实链接 + 部分信任信号（销量 or 评分）
3	基础商品卡 or 链接但缺信任信号 or 链接仅到搜索页
2	纯文本商品名 + 无链接 or 死链 / 推荐到低销量低评分商品

1	完全无商品卡承接 / 推荐到违规/低质商家
---	-----------------------

附加扣分规则（V5 新增）：

触发条件	维度 6 扣分
卡片样式问题（见 § 9.6.1）	-1 分
推荐到低评分（< 3.5） or 低销量（< 10）商品	-1 分
WebFetch URL 失败率 > 50% → 加挂 <code>dead_link</code>	-1 分
<code>card_missing</code>	维度 6 = 1 + 触发 OVF-4

评估样例：

✔ Good Case（5 分）：

render_data: 1 个 hero_card + 2 个 mini_card，每个 product 含图/价/商家/销量/评分
final_items[0]: shop="Apple 官方旗舰店", sold_count=10000+, rating=4.9
final_items[1]: shop="华硕官方旗舰店", sold_count=5000+, rating=4.8
评分理由: 卡片完整结构正确 + 大牌官方店 + 高销量高评分 → 5 分



● Middle Case（3 分）：

render_data: 基础商品卡（图+价+商家），缺销量/评分字段
final_items: 商家是普通卖家（非官方店），销量 100+
评分理由: 卡片可用但缺信任信号 + 商家质量中等 → 3 分



✖ Bad Case（1 分）：

should_recommend = yes
render_data: 空
answer_text: 纯文本品牌名，无任何商品链接
评分理由: 完全无承接 → card_missing → OVF-4 → 维度 6 = 1 + Fail
sub: card_missing / no_product_card

9.6.1 卡片样式评估细则

5 类卡片正确用法：

type	正确场景	不应使用
item_hero_card	唯一主推（每轮至多 1 个）、detail_qa 被问的那个商品	多商品并列都用 hero
item_mini_card	多商品推荐 / 列表 / 备选	当轮唯一主推却用 mini
image_gallery	用户关注外观 / 图片 / 款式 / 颜色，且 images $\geq$ 2	images < 2、非视觉场景
item_link	正文短引用 / 轻量跳转，text 简短可读	用作商品卡展示；text 空 / 过长
item_comparison_table	compare 场景，含完整 ref_ids / products / attributes	非 compare；缺 products / attributes

「1 个 hero + 若干 mini」是正确的**主次结构**，不要据此判错。

卡片样式问题与扣分（V5 改：扣分流向维度 6）：

轻微问题（维度 6 -1 分，记对应 sub_problem_type）：

sub_problem_type	触发条件
wrong_card_type	多商品都标 hero / 该用对比表却用普通卡 / 该 hero 主推却用 mini
card_multiple_hero	非 compare 场景出现 $\geq$ 2 个 item_hero_card
card_image_scroller_no_images	image_gallery 的 images 数组 < 2
card_comparison_table_misuse	对比表缺 products / attributes 字段，或非 compare 场景误用
card_link_empty_text	item_link 的 text 字段为空或过长

严重问题（触发 OVF-4，走 no_product_card）：

sub_problem_type	触发条件
card_missing / no_product_card	should_recommend=yes 且 final_items 非空，但 render_data 为空、answer_text 也无任何商品链接 → 商品完全无法触达

判定原则：

- 多个卡片问题同时出现 → 取最重一项，不累加扣分
- 不要因商品本身不相关就把卡片样式判错（商品内容问题交给维度 1/4 处理）
- 不要因看不到前端真实渲染而判错
- 不要因正文是 markdown 链接而判错（markdown 链接是卡片锚文本，正常）

card_style_eval 必填结构化输出（每轮一个，放入 **score_breakdown.per_turn_scores[]**）：

字段	取值
状态	SKIP（无 render_data 或不需展示商品） / PASS（无问题） / FAIL（命中任一问题）
卡片类型	render_data 里实际出现的 type 去重列表（如 ["item_hero_card","item_mini_card"]）；SKIP 时填 []
问题	no_issue / wrong_card_type / card_multiple_hero / card_image_scroller_no_images / card_comparison_table_misuse / card_link_empty_text / card_missing
说明	中文 1 句判断依据
affects_dimension_6	本轮卡片样式对维度 6 用户体验的扣分（0 或 1；card_missing 不在此扣，走 OVF-4）

十、item-level rollup 详细算法

10.1 适用维度

维度	rollup 类型
维度 1 商品相关性	✔ item-level rollup
维度 2 推荐理由	✘ set-level（直接打 1 个分）
维度 3 完整性与多样性	✘ set-level
维度 4 事实准确性	✔ item-level rollup
维度 5 时效信息可信度	✔ item-level + URL 验证 + rollup
维度 6 用户体验	🟡 混合（卡片 set + 商品质量 item rollup，取最低）

10.2 1/rank 加权归一化公式

$$\text{rank_weight}_i = (1 / \text{rank}_i) / \sum (1 / \text{rank}_j)$$
$$\text{dim_score} = \sum (\text{per_item_dim_score}_i \times \text{rank_weight}_i)$$

10.3 常见权重表

N	rank 权重数组
1	[1.000]
2	[0.667, 0.333]
3	[0.545, 0.273, 0.182]
4	[0.480, 0.240, 0.160, 0.120]
5	[0.438, 0.219, 0.146, 0.110, 0.088]

10.4 计算示例

示例 1（N=3，维度 1 分别 5/4/2）：

$$\begin{aligned} \text{dim}_1 &= 5 \times 0.545 + 4 \times 0.273 + 2 \times 0.182 \\ &= 2.725 + 1.092 + 0.364 \\ &= 4.18 \end{aligned}$$



示例 2（同样 N=3，但 2 分商品在 rank=1 vs rank=3 的差异）：

组合 A: rank=1 给 2 分，rank=2/3 给 5/4 分

$$\text{dim}_1 = 2 \times 0.545 + 5 \times 0.273 + 4 \times 0.182 = 1.09 + 1.37 + 0.73 = 3.19$$

组合 B: rank=3 给 2 分，rank=1/2 给 5/4 分

$$\text{dim}_1 = 5 \times 0.545 + 4 \times 0.273 + 2 \times 0.182 = 2.73 + 1.09 + 0.36 = 4.18$$

→ rank=1 的错误，杀伤力比 rank=3 错误大 1 分（3.19 vs 4.18）

10.5 无商品兜底

情况	item-level 维度处置	set-level 维度处置
should_recommend=yes 但 final_items 为空	维度 1/4/5 = 1（通常同时触发 OVF-4），维度 6 = 1	维度 2/3 正常评

should_recommend=no 且 final_items 为空	维度 1/4/5 = 5 (兜底)	维度 2/3 正常评
---	-------------------	------------

十一、每轮分公式 (Step 3 总结)

11.1 单轮 case

$$\begin{aligned} \text{per_turn_score} = & \text{商品相关性分} \times W_1 \\ & + \text{推荐理由质量分} \times W_2 \\ & + \text{完整性多样性分} \times W_3 \\ & + \text{事实准确性分} \times W_4 \\ & + \text{时效信息可信度分} \times W_5 \\ & + \text{用户体验分} \times W_6 \end{aligned}$$

$W_1 \dots W_6$ 来自 § 8.2 按 intent_type 取列
 $\text{case_overall_score} = \text{per_turn_score}$

11.2 计算示例

query: 「5000 元能打游戏的笔记本」 (semi_precise_lookup)

6 个维度分:

- 商品相关性 = 4
- 推荐理由质量 = 4
- 完整性多样性 = 3 (推了 1 个超预算未标注)
- 事实准确性 = 4
- 时效信息 = 4 (URL 验证 OK 但缺时效标注)
- 用户体验 = 4

权重 (semi_precise_lookup):

$W_1=0.27, W_2=0.16, W_3=0.20, W_4=0.13, W_5=0.13, W_6=0.11$

$$\begin{aligned} \text{per_turn_score} &= 4 \times 0.27 + 4 \times 0.16 + 3 \times 0.20 + 4 \times 0.13 + 4 \times 0.13 + 4 \times 0.11 \\ &= 1.08 + 0.64 + 0.60 + 0.52 + 0.52 + 0.44 \\ &= 3.80 \end{aligned}$$

$\text{case_overall_score} = 3.80 \rightarrow \text{Needs Work}$

☐

十二、Step 4 — 跨轮 4 维度 (仅多轮)

12.1 上下文交互一致性 context_consistency_score (1-5)

跨轮是否记住 预算 / 品牌 / 规格 / 尺寸 / 颜色 / 材质 / 排斥条件 / 人群 / 场景 / 平台 / 配送 / 保修 / 已选商品。

分	锚点
5	全部约束维持
4	轻微遗忘但不影响
3	部分关键约束被忽略
2	多个关键约束丢失
1	完全忘记前文

12.2 目标达成 goal_achievement_score (1-5 + status)

分	锚点	status
5	完全达成 + 明确承接	achieved
4	基本达成但承接弱	achieved
3	部分达成	partial
2	大部分未满足	partial
1	完全未满足 / 偏离	not_achieved

12.3 任务推进 task_progression_score (1-5)

分	锚点
5	每轮明显推进（澄清 → 候选 → 对比 → 决策 → 承接）
4	大多数轮推进
3	部分轮打转
2	多轮重复追问 / 输出
1	几乎无进展

12.4 闭环承接 closure_quality_score

closure_quality	标准	分
good	具体商品 / 方案 + 购买链接 / 承接 + 规格确认	5
weak	有商品 / 方案，但缺关键链接 / 规格 / 承接	3
missing	用户明确要下单 / 链接但未承接	1
not_applicable	不需要 closing	4

十三、Step 5 — 总分

13.1 单轮总分

☑case_overall_score = per_turn_score (来自 § 11.1)

☑13.2 多轮总分

☑turn_weight:

- closing = 2.0
- comparison_request = 1.5
- 其他 = 1.0

weighted_turn_avg = $\Sigma(\text{per_turn_score}_i \times \text{turn_weight}_i) / \Sigma(\text{turn_weight}_i)$

case_overall_score =

- weighted_turn_avg × 45% # 承载轮内 6 维度
- + goal_achievement_score × 25%
- + context_consistency_score × 15%
- + task_progression_score × 10%
- + closure_quality_score × 5%

☑

保留 1 位小数。

13.3 多轮计算示例

3 轮：T1=4.2（initial_query 权重 1.0），T2=3.8（comparison_request 权重 1.5），T3=4.8（closing 权重 2.0）

☒weighted_turn_avg:

分子 = $4.2 \times 1.0 + 3.8 \times 1.5 + 4.8 \times 2.0 = 4.2 + 5.7 + 9.6 = 19.5$

分母 = $1.0 + 1.5 + 2.0 = 4.5$

= $19.5 / 4.5 = 4.33$

跨轮维度: goal=5, ctx=4, prog=4, closure=5

case_overall_score =

$4.33 \times 0.45 + 5 \times 0.25 + 4 \times 0.15 + 4 \times 0.10 + 5 \times 0.05$

= $1.949 + 1.25 + 0.60 + 0.40 + 0.25$

= $4.45 \rightarrow 4.5$

☒

十四、Step 6 — 状态判定

☒if 命中任一 OVF:

status = Fail

elif case_overall_score ≥ 4.0:

status = Pass

elif case_overall_score ≥ 3.0:

status = Needs Work

else:

status = Fail

☒

状态	条件
Pass	未触发一票否决，且 $\text{case_overall_score} \geq 4.0$
Needs Work	未触发一票否决，且 $3.0 \leq \text{case_overall_score} < 4.0$
Fail	触发一票否决，或 $\text{case_overall_score} < 3.0$

十五、Step 7 — 单一诊断（V5 核心改造）

15.1 main_problem_type = 评估维度 1:1 映射

main_problem_type	触发条件
商品相关性问题	维度 1 扣分最重
推荐理由与表达质量问题	维度 2 扣分最重
完整性与多样性问题	维度 3 扣分最重
事实准确性问题	维度 4 扣分最重
时效信息可信度问题	维度 5 扣分最重
用户体验问题	维度 6 扣分最重
无明显问题	所有维度 ≥ 4 分且无 OVF
评测输入问题	缺必要输入无法评估

15.2 sub_problem_type 完整树形（按 6 维度分组）

A. 商品相关性问题（sub）

sub	判断细则
wrong_category	商品大类错误（要 laptop 给 phone case）
weak_category_match	大类相关但偏离核心用途（要"防水徒步鞋"给普通休闲鞋）
wrong_brand_or_model	用户指定品牌/型号但结果不匹配
constraint_mismatch	不满足正向核心约束（预算/规格/颜色等）
negative_constraint_violation	违反否定条件（"not refurbished" 还推翻新）
compare_object_missing	compare 漏掉核心对比对象
wrong_intent_understanding	理解错商品/品牌/场景导致推荐方向偏
ignored_constraint	显式约束完全没接住

B. 推荐理由与表达质量问题（sub）

sub	判断细则
generic_reasoning	推荐理由全通用词无锚点（"comfortable / 好用"）

poor_structure	语言结构混乱难读
missing_decision_framework	缺 if-then / 取舍建议
shallow_explanation	教育性弱、关键术语未解释
lack_anchored_facts	缺事实锚点（无数字/技术词/具体场景）
lack_takeaway_suggestion	评估场景缺明确结论 / compare 缺取舍建议
unsupported_claim	言之凿凿但 final_items 无依据（如说"BPOM 认证"但 attributes 无）
misleading_reasoning	推荐理由明显误导（入门款说成专业级）
safety_risk	健康/儿童/药品场景给确定性承诺
under_clarification	该澄清不澄清
over_clarification	用户已明确仍只追问

C. 完整性与多样性问题（sub）

sub	判断细则
missing_items	应推未推
insufficient_candidates	候选数明显不足（精准要求 1，半精准/模糊 < 3）
low_spu_diversity	SPU 多样性差（含同店伪 SPU 重复，如同款不同 motif）
low_category_diversity	品类多样性差（场景化下集中在 1 个品类）
low_offer_diversity	Offer 多样性差（精准找下仅 1 个 offer）
low_price_diversity	价位多样性差（模糊找下未跨档）
low_brand_diversity	品牌多样性差（反复推同品牌）
incomplete_compare	compare 维度 < 3 / 缺取舍建议
missing_next_step	缺下一步 refine / 追问 / 折叠备选
incomplete_answer	遗漏核心问题或关键约束
lack_layered_structure	场景化缺"必备/进阶/锦上添花"分层
over_narrowing	收敛过度（如模糊找直接推 1-2 款不给方向）

D. 事实准确性问题 (sub)

sub	判断细则
incorrect_product_attribute	商品属性错位（说"OLED"实际是"IPS"）
directly_contradicted_claim	推荐说明被 final_items 直接证伪
fabricated_attribute	编造商品 final_items 不含的属性
wrong_brand_or_model_info	品牌/型号身份错位（标"ROG"实际是"TUF"）
image_mismatch	agent 描述与商品图片不符（颜色/形状/材质）
spec_misrepresentation	规格读错（如把 4G 说成 5G）
overconfident_product_claim	数据不足却给确定性判断

E. 时效信息可信度问题 (sub) ★ V5 强 URL 验证

sub	判断细则	验证方式
fabricated_price	编造价格（agent 价格 $\neq$ PDP，偏差 $> 20\%$ ）	URL 实地核对
price_inaccuracy	价格偏差 5-20%	URL 实地核对
fabricated_stock	编造库存（说"现货"实际无货）	URL 实地核对
stock_inaccuracy	库存信息略偏离	URL 实地核对
fabricated_shipping	编造物流信息（"次日达"实际无承诺）	URL 实地核对
fabricated_promo	编造"限时立减""国补"等促销	URL 实地核对
seller_misrepresentation	卖家身份错位（说"官方店"实际是第三方）	URL 实地核对
missing_time_label	缺"截至 X 时间"时效性标注	看 answer 文本
time_sensitive_unverifiable	URL 缺失/失效，无法验证（降级 3 分）	URL 访问失败时
link_to_aggregation_page	URL 跳到聚合页非 SKU 详情页	URL 实地访问

F. 用户体验问题 (sub)

sub	判断细则
card_missing / no_product_card	should_recommend=yes 但 render_data 为空且无任何商品链接（触发 OVF-4）
wrong_card_type	多商品都标 hero / 该用对比表却用普通卡
card_multiple_hero	非 compare 场景出现 ≥ 2 个 item_hero_card
card_image_scroller_no_images	image_gallery 的 images 数组 < 2
card_comparison_table_misuse	对比表缺 attributes 字段，或非 compare 场景误用
card_link_empty_text	item_link 的 text 字段为空或过长
low_visual_richness	缺多模态承载（图/视频/对比表）
low_seller_quality	推荐到低评分（ < 3.5 ） / 低销量（ < 10 ） / 认证缺失商家
dead_link	商品链接访问失败/404，且连续 ≥ 2 个失败
link_misroute	链接跳到非目标商品

G. 评测输入问题（sub）

sub	判断细则
eval_input_missing	缺必要输出 / tool 信息 / 商品快照，无法判断
expected_outcome_conflict	expected_outcome 与实际不一致
snapshot_incomplete	商品快照不完整

H. 无明显问题

sub	判断细则
no_issue	所有维度均可接受，结果整体可用

15.3 优先级（多维同低时）

全局严重度兜底：

- ☒商品相关性 > 事实准确性 > 时效信息可信度
- > 推荐理由与表达质量 > 完整性与多样性 > 用户体验

> 评测输入

☒

OVF 强制映射（覆盖上面优先级）：

OVF	强制 main_problem_type	推荐 sub
OVF-1	商品相关性问题	wrong_category / weak_category_match 等
OVF-2	商品相关性问题	negative_constraint_violation
OVF-3	商品相关性问题	compare_object_missing
OVF-4	用户体验问题	card_missing / no_product_card
OVF-5（编造交易信息）	时效信息可信度问题	fabricated_price / fabricated_promo 等
OVF-5（编造既定事实）	事实准确性问题	directly_contradicted_claim / wrong_brand_or_model_info 等
OVF-6	推荐理由与表达质量问题	safety_risk
OVF-7	用户体验问题	card_missing / low_visual_richness

十六、Step 8 — 链路归因 root_cause

root_cause	含义
no_issue	无明显问题
data_quality_issue	商品数据缺失 / 错误 / 过期 / 不可信（在 final_items / render_data[].product 层面已不全 / 不可信）
retrieval_issue	召回错类 / 候选不足 / 排序错误 / 核心对象未召回
ecommerce_tool_generation_issue	电商 tool 的 answer / reason / 解释生成错误
caller_agent_processing_issue	调用方 Agent 丢商品 / 改错 / 漏卡 / 误加工
context_passing_issue	历史约束 / memory / 对比对象 / 已推商品未传递
display_or_card_issue	有结果但卡片 / 图片 / 链接 / 价格展示异常；或 render_data 卡片类型选用错误

policy_or_safety_issue	高风险场景表达过强或误导
system_runtime_issue	timeout / 无响应 / token 耗尽 / 服务异常
eval_input_issue	评测输入 / 上下文 / 商品快照不完整

层级一致性：

- tool 通过 + final 失败 → caller_agent_processing_issue
- tool 失败 → retrieval / data_quality / tool_generation 细分

第四部分 · 输出与质量保障

☒十八、字段对齐规范

字段	对齐要求
A-评估结果.状态	= status 大写映射（Pass→PASS / Needs Work→NEEDS_WORK / Fail→FAIL）
A-评估结果.case_overall_score	= score
A-评估结果.结果分析	= problem_summary
A-评估结果.main_problem_type	= main_problem_type
A-评估结果.sub_problem_type	= sub_problem_type
A-评估结果.intent_type	= intent_type
单轮 case	score_breakdown 中跨轮维度填 null，只填 per_turn_scores

十九、评估自检清单

完成评估后，逐条核对：

- a. ☒ 已识别 intent_type（8 选 1）并据 § 8.2 查到 6 维权重？
- b. ☒ 6 维度都打分了？ item-level 维度（1/4/5）按 1/rank 加权 rollup？
- c. ☒ 维度 5 是否对每个 final_items[].url 调用 WebFetch 实地验证？ 验证降级矩阵正确处理 url_missing / fetch_failed / aggregation_page？
- d. ☒ 卡片样式扣分流向维度 6（不再扣 answer_score）？ card_missing 仍触发 OVF-4？
- e. ☒ per_turn_score = Σ(维度分 × 权重)？ 单轮 case_overall_score = per_turn_score？

- f. ☒ 多轮总分 = $\text{weighted_turn_avg} \times 45\% + \text{goal} \times 25\% + \text{ctx} \times 15\% + \text{prog} \times 10\% + \text{closure} \times 5\%$?
- g. ☒ 命中任一 OVF $\rightarrow \text{status} = \text{Fail}$? OVF-5 触发条件是否包括 URL 验证发现编造? 对应意图类型的 OVF-1 是否放宽?
- h. ☒ 只标一个 `main_problem_type`, 且 = 拉低分最重的维度 (1:1)? OVF 强制映射规则正确?
- i. ☒ `dimension_scores` / `time_sensitive_verify` / `card_style_eval` 三个新字段都填了?
- j. ☒ A-评估结果 与顶层结论完全一致?

二十、判定速查表 (V5 更新)

现象	归类
render_data 出现 2 个 hero_card (非 compare)	<code>card_multiple_hero</code> $\rightarrow$ 用户体验问题, 维度 6 -1
image_gallery images 只有 1 张	<code>card_image_scroller_no_images</code> $\rightarrow$ 用户体验问题, 维度 6 -1
compare 场景用 hero/mini 而非 comparison_table	<code>wrong_card_type</code> $\rightarrow$ 用户体验问题, 维度 6 -1
comparison_table 缺 attributes	<code>card_comparison_table_misuse</code> $\rightarrow$ 用户体验问题, 维度 6 -1
item_link text 为空	<code>card_link_empty_text</code> $\rightarrow$ 用户体验问题, 维度 6 -1
should_recommend=yes 但 render_data 空 且正文无任何商品链接	<code>card_missing</code> / <code>no_product_card</code> $\rightarrow$ OVF-4 $\rightarrow$ Fail
render_data 缺失 (旧格式), 但正文有商品 markdown 链接	跳过卡片样式评估, 正常评
正文 <code>[商品名](url)</code>	卡片锚文本, 正常, 不算缺卡/卡片用错
agent 说 "S\$129", final_items 就是 S\$129	可信 $\checkmark$ (维度 4)
agent 说 "BPOM 认证", attributes 无此字段	<code>unsupported_claim</code> $\rightarrow$ 推荐理由与表达质量问题
agent 说 "S\$99", PDP 实际 "S\$129"	<code>fabricated_price</code> + OVF-5 $\rightarrow$ 时效信息可信度问题
URL 字段缺失 / WebFetch 失败	<code>time_sensitive_unverifiable</code> $\rightarrow$ 维度 5 默认 3 分
WebFetch 返回聚合搜索页非 SKU 详情页	<code>link_to_aggregation_page</code> $\rightarrow$ 维度 5 = 3
WebFetch 失败率 > 50%	升级到 <code>dead_link</code> $\rightarrow$ 用户体验问题
推荐商品类目与 query 完全不符	<code>wrong_category</code> $\rightarrow$ 商品相关性问题 + OVF-1

用户说"不要黑色", agent 推黑色	OVF-2 → 商品相关性问题
closing 轮要链接, render_data 无 item_link 且正文无购买链接	OVF-7 → 用户体验问题
推荐到低评分 (< 3.5) / 低销量 (< 10) 的商品	low_seller_quality → 用户体验问题, 维度 6 -1
推 5 款衬衫, 第 1/2 款同 shop_id 同价同 description	low_spu_diversity → 完整性与多样性问题
ASUS A7M5 vs Fujifilm XT5 对比, 但用 hero_card 罗列	wrong_card_type → 用户体验问题, 维度 6 -1

第五部分 · 端到端评估示例

二十一、Case A：完整 Pass 示例（单轮）

输入：

☑user_query: "iPhone 15 Pro 256GB 黑色"

intent_type: precise_lookup

agent answer_text:

"找到 iPhone 15 Pro 256GB 黑色（自然钛金属）。A17 Pro + USB-C + 3x 光变。

3 个 offer:

- Apple 官店 ¥7999（24 期免息）
- JD 自营 ¥7899（PLUS ¥7504）
- 拼多多百亿补贴 ¥7299

推荐 JD 自营（保修+物流+价格最平衡）。"

final_items: [{

"item_id": "jd_123",
"title": "iPhone 15 Pro 256GB 黑色（自然钛金属）",
"price": "¥7899",
"url": "<https://jd.com/...>",
"seller": "JD 自营",
"rating": 4.9,
"sold_count": 100000,
"attributes": {"storage": "256GB", "color": "Black Titanium"}

}, ...]

WebFetch 验证: 全部 URL 可访问, 价格/库存/卖家全对



评分过程:

☑维度权重 (precise_lookup) :

$W_1=0.33, W_2=0.16, W_3=0.09, W_4=0.16, W_5=0.16, W_6=0.10$

6 个维度分:

- 维度 1 商品相关性 = 5 (item-level rollup: 全 5)
- 维度 2 推荐理由质量 = 4 (有 offer 排序逻辑, 含数字锚点, 缺替代品)
- 维度 3 完整性多样性 = 5 (3 个 offer 差异化标注 + 明确购买推荐)
- 维度 4 事实准确性 = 5 (item-level rollup: 全 5)
- 维度 5 时效信息可信度 = 5 (URL 验证全对)
- 维度 6 用户体验 = 5 (大牌 + 高销量 + 高评分)

$$\begin{aligned}\text{per_turn_score} &= 5 \times 0.33 + 4 \times 0.16 + 5 \times 0.09 + 5 \times 0.16 + 5 \times 0.16 + 5 \times 0.10 \\ &= 1.65 + 0.64 + 0.45 + 0.80 + 0.80 + 0.50 \\ &= 4.84\end{aligned}$$

case_overall_score = 4.84 → Pass



诊断: 所有维度 $\geq 4 \rightarrow$ main = 无明显问题

二十二、Case B: OVF-5 Fail 示例 (编造价格)

输入:

☑user_query: "iPhone 15 Pro 256GB 现在多少钱"

intent_type: detail_qa

agent answer_text:

"JD 当前秒杀 ¥4999, 国补 50% 后 ¥2499, 明天涨价回 ¥7899! 手慢无!"

final_items: [{

"item_id": "jd_123",

"url": "<https://jd.com/iphone-15-pro-256gb-black>",

...

}]

WebFetch(url) → PDP:

current_price: ¥7899

active_promos: [] # 无国补、无秒杀



评分过程:

☑ 维度 5 时效信息可信度:

URL 实地验证发现 agent 价格 ¥4999 ≠ PDP ¥7899 (偏差 60%)

+ 编造"国补 50%" + 编造"秒杀" + 编造"明天涨价"

→ 该 item dim 5 = 1 + 触发 OVF-5

其他维度: 维度 1=5 (品类对), 维度 2=2 (误导), 维度 3=4, 维度 4=4, 维度 6=3

$$\text{per_turn_score} = 5 \times 0.24 + 2 \times 0.32 + 4 \times 0.05 + 4 \times 0.22 + 1 \times 0.09 + 3 \times 0.08$$

$$= 1.20 + 0.64 + 0.20 + 0.88 + 0.09 + 0.24$$

$$= 3.25$$

但 OVF-5 触发 → status = Fail



诊断: OVF-5 强制 → main = 时效信息可信度问题, sub = fabricated_price

二十三、Case C: 多样性问题 (同店伪 SPU)

输入:

☑ user_query: "日常休闲衬衫"

intent_type: vague_lookup

agent: 推 5 款, 但 item[0] 和 item[1] 同 shop_id (564494110)、同价 Rp56,800、

description 几乎一字不差, 只是 motif 名不同 (SEMNI vs KML_WLF)



评分过程:

☑ 维度权重 (vague_lookup):

$$W_1=0.22, W_2=0.20, W_3=0.22, W_4=0.13, W_5=0.13, W_6=0.10$$

6 个维度分:

- 维度 1 商品相关性 = 4 (品类对, 约束都对)

- 维度 2 推荐理由质量 = 3 (理由偏通用, 缺切片引导)

- 维度 3 完整性多样性 = 3 (候选 5 个但前 2 个伪 SPU 重复 → low_spu_diversity)

- 维度 4 事实准确性 = 4

- 维度 5 时效信息可信度 = 4

- 维度 6 用户体验 = 4

$$\text{per_turn_score} = 4 \times 0.22 + 3 \times 0.20 + 3 \times 0.22 + 4 \times 0.13 + 4 \times 0.13 + 4 \times 0.10$$
$$= 0.88 + 0.60 + 0.66 + 0.52 + 0.52 + 0.40$$
$$= 3.58$$

case_overall_score = 3.58 → Needs Work

☒

诊断：维度 3 扣分最重（3 分）→ main = 完整性与多样性问题，sub = low_spu_diversity

第六部分 · 附录

二十四、术语速查

术语	含义
SKU	Stock Keeping Unit，最小库存单位（具体到颜色/规格）
SPU	Standard Product Unit，标准产品单位（一个商品类）
PDP	Product Detail Page，商品详情页
OVF	One-Vote Fail，一票否决
Hero card	单商品大卡（主推商品用）
Mini card	单商品小卡（备选商品用）
1/rank 加权	调和加权，rank 越靠前权重越大
Item-level rollup	按 item 单独打分后用 1/rank 加权汇总
Set-level	把整组推荐当一个整体直接打 1 个分

二十五、文档维护

版本	日期	主要变更	维护者
----	----	------	-----

V5.0	2026-06	6 维度直接打分 + URL 验证 + main 1:1 映射	—
V4	2025	7 维（含耗时） + answer/item 配比	—

二十六、一句话总结

V5 = 把"问题归类"和"评估维度"对齐（main = 维度 1:1），去掉耗时维度，重设权重，并强制 judge 在评时效信息可信度时实地访问 URL 核对 PDP 数据。所有 sub problem 都挂在 6 个维度下，PM / judge 评分时不再纠结"这个问题归到哪类"——按对应维度自然落位；item-level rollup 沿用 V4 的 1/rank 加权精神，确保前位商品的错误杀伤力大于后位。